ESTADO DEL ARTE Y DE LA TÉCNICA - BIOINGENIERÍA II

Juan Carlos Orozco Pulido – Elimelec José Ricardo Melo

PLATAFORMA WEB PARA EL ANÁLISIS AUTOMÁTICO Y OPTIMIZADO DE SEÑALES ECG CON VISUALIZACIÓN MULTIUSUARIO

RESUMEN -ABSTRACT

El electrocardiograma (ECG) constituye la herramienta diagnóstica de referencia para la detección y monitorización de enfermedades cardiovasculares, cuya interpretación automatizada depende de manera crítica de la calidad del procesamiento aplicado a la señal. En este contexto, el presente proyecto de investigación desarrolla una revisión exhaustiva del estado del arte y del estado de la técnica en métodos de filtrado, análisis y clasificación de señales ECG. Dicha revisión abarca técnicas clásicas, como filtros FIR, IIR y notch; métodos adaptativos LMS, NLMS, RLS y sus variantes; transformadas wavelet DWT y SWT; técnicas de descomposición modal EMD, EEMD, VMD e IF; así como modelos de aprendizaje profundo, entre ellos DAE, CNN 1D y LSTM. Estas metodologías se analizan y comparan mediante evaluaciones cuantitativas basadas en métricas como SNR, MSE, PRD y SSIM, empleando bases de datos estandarizadas ampliamente utilizadas en la literatura, tales como MIT-BIH y PTB-XL.

Asimismo, se examina el panorama de plataformas y arquitecturas existentes para el procesamiento de ECG —incluyendo entornos web, cloud, edge/IoT e híbridos— junto con los estándares y formatos de datos más relevantes (DICOM, WFDB, HL7/FHIR y CSV) y las herramientas actuales de visualización e interacción. Este análisis permite identificar brechas críticas relacionadas con la accesibilidad, la integración completa del pipeline de procesamiento y la interoperabilidad clínica.

A partir de este análisis comparativo, y como respuesta directa a las limitaciones detectadas en la literatura, se justifica y se propone el desarrollo de una plataforma web de arquitectura híbrida local–cloud. La plataforma incorpora un backend científico en Python, implementado mediante FastAPI e integrando librerías como NumPy, SciPy, PyWavelets, TensorFlow y WFDB, junto con un frontend interactivo desarrollado en HTML5, CSS3 y JavaScript, utilizando Plotly.js y D3.js. Este enfoque permite integrar de forma unificada el filtrado avanzado, la clasificación mediante aprendizaje profundo y la comparación interactiva de métricas, ofreciendo una solución accesible tanto para usuarios expertos como no expertos. De este modo, la propuesta contribuye a reducir la brecha existente entre la investigación biomédica y la práctica clínica en el análisis automatizado de señales cardíacas.

The electrocardiogram (ECG) is the reference diagnostic tool for the detection and monitoring of cardiovascular diseases, and its automated interpretation critically depends on the quality of the signal processing applied. In this context, this research project presents a

comprehensive review of the state of the art and the state of the technique in ECG signal filtering, analysis, and classification methods. The review covers classical techniques, such as FIR, IIR, and notch filters; adaptive methods including LMS, NLMS, RLS, and their variants; wavelet transforms (DWT and SWT); modal decomposition techniques (EMD, EEMD, VMD, and IF); and deep learning models, including denoising autoencoders (DAE), one-dimensional convolutional neural networks (1D CNN), and long short-term memory networks (LSTM). These approaches are evaluated through quantitative analysis using SNR, MSE, PRD, and SSIM metrics on well-established benchmark databases, namely MIT-BIH and PTB-XL.

In addition, the landscape of existing ECG processing platforms and system architectures—encompassing web-based, cloud, edge/IoT, and hybrid solutions—is analyzed, together with the most relevant data standards and formats (DICOM, WFDB, HL7/FHIR, and CSV) and current visualization and interaction tools. This analysis reveals critical gaps in accessibility, end-to-end pipeline integration, and clinical interoperability across existing solutions.

Based on this comparative assessment, and as a direct response to the identified limitations, the development of a hybrid local–cloud web platform is justified and proposed. The platform is built upon a scientific Python backend implemented using FastAPI and integrating NumPy, SciPy, PyWavelets, TensorFlow, and WFDB, along with an interactive frontend developed in HTML5, CSS3, and JavaScript using Plotly.js and D3.js. This architecture enables the unified integration of advanced filtering techniques, deep learning–based classification, and interactive metric comparison, providing an accessible solution for both expert and non-expert users. Consequently, the proposed platform contributes to bridging the gap between biomedical research and clinical practice in automated cardiac signal analysis.

PALABRAS CLAVE

procesamiento de señales ECG, filtrado adaptativo, transformada wavelet discreta, descomposición modal empírica, aprendizaje profundo, plataforma web, FastAPI, visualización interactiva, arquitectura híbrida edge–cloud, interoperabilidad clínica

1. INTRODUCCIÓN

El electrocardiograma (ECG) es una de las herramientas diagnósticas más utilizadas en medicina; sin embargo, su análisis continúa dependiendo en gran medida de software especializado y de personal altamente capacitado, lo que restringe su uso a entornos clínicos específicos y limita su accesibilidad en contextos educativos, de investigación y de atención primaria. Esta dependencia tecnológica y humana dificulta la adopción de soluciones de análisis ECG más flexibles, escalables y accesibles para distintos perfiles de usuario.

En respuesta a esta problemática, el presente proyecto propone el desarrollo de una plataforma web para el procesamiento automático y optimizado de señales ECG crudas,

con capacidad de visualización multiusuario. La plataforma integra etapas de filtrado adaptativo, detección de picos R y cálculo de parámetros cardíacos clave, proporcionando resultados a través de una interfaz diferenciada que atiende tanto a usuarios expertos como al público general.

Este enfoque se fundamenta en la necesidad de combinar eficiencia computacional, accesibilidad y facilidad de uso en una única solución, permitiendo extender el análisis de señales ECG más allá de los entornos clínicos tradicionales y favoreciendo su aplicación en escenarios de educación, investigación y salud digital. De este modo, la plataforma propuesta busca contribuir a la democratización del análisis ECG mediante herramientas web accesibles y técnicamente robustas.

La Figura 1 presenta una visión general del pipeline de procesamiento de señales ECG considerado en este trabajo, integrando las etapas de filtrado, detección de ondas, extracción de características, clasificación automática y visualización, en concordancia con el estado del arte revisado y la arquitectura de la plataforma propuesta.

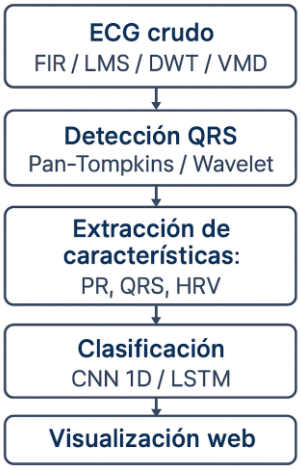

Figura 1. Pipeline general de procesamiento y análisis de señales ECG desde la señal cruda hasta la visualización web de resultados.

PROCESAMIENTO DE SEÑALES ECG

2.1 Técnicas existentes

La literatura reciente ofrece un panorama amplio de métodos clásicos y avanzados para el procesamiento de señales ECG, que abarca desde filtros digitales FIR/IIR y filtrado adaptativo (LMS, RLS) hasta la descomposición en wavelets, EMD y modelos de aprendizaje profundo. Los estudios comparativos emplean métricas cuantitativas como el SNR, el MSE y el PRD para evaluar la fidelidad de la señal reconstruida, complementadas con criterios de preservación morfológica que valoran la integridad de los complejos QRS, las ondas P y T y los intervalos clínicamente relevantes.

Tipos de ruido en ECG y filtros clásicos

En conjunto, estos resultados demuestran que, si bien los filtros clásicos FIR, IIR y notch son eficientes y de baja complejidad para la eliminación de ruidos estacionarios específicos como la PLI, resultan insuficientes como solución única ante escenarios clínicos reales dominados por ruido no estacionario. Esta limitación justifica la incorporación de técnicas más adaptativas y flexibles en el sistema propuesto.

Filtros adaptativos

Lo anterior evidencia que los filtros adaptativos ofrecen un mejor desempeño frente a ruidos no estacionarios y artefactos de movimiento, manteniendo una complejidad computacional compatible con aplicaciones en tiempo real. Por esta razón, estos algoritmos constituyen un componente clave dentro del pipeline de procesamiento de la plataforma propuesta, especialmente en escenarios de adquisición dinámica o ambulatoria.

Denoising basado en wavelets (DWT, SWT y variantes)

En consecuencia, la DWT y sus variantes representan un compromiso adecuado entre calidad de filtrado, preservación morfológica y complejidad computacional. Esta combinación de propiedades fundamenta su selección como una de las técnicas centrales de denoising integradas en la plataforma propuesta, particularmente para señales ECG con ruido compuesto.

EMD, filtrado iterativo y enfoques basados en modos

Estos resultados ponen de manifiesto que los enfoques basados en descomposición modal ofrecen una elevada capacidad de adaptación a la dinámica no estacionaria del ECG, a costa de un mayor coste computacional. Por ello, en el sistema propuesto, estas técnicas se contemplan principalmente para análisis avanzados u offline, complementando métodos más ligeros empleados en procesamiento en tiempo real.

Enfoques híbridos avanzados

En síntesis, los métodos híbridos optimizados representan el estado del arte en términos de desempeño cuantitativo y preservación morfológica, aunque su elevada complejidad limita su aplicación directa en sistemas embebidos o de baja latencia. Este análisis justifica que la

plataforma propuesta adopte una arquitectura flexible, capaz de integrar dichos enfoques en entornos con mayor capacidad de cómputo, sin comprometer la eficiencia del procesamiento básico.

Comparación de rendimiento y preservación morfológica

La evaluación cuantitativa de los métodos de filtrado de ECG recurre a un conjunto de métricas complementarias que permiten valorar tanto la fidelidad de la señal reconstruida como la integridad de sus componentes clínicamente relevantes; las más empleadas en la literatura reciente son SNR y SNRimp, MSE y RMSE, PRD, SSIM y correlación cruzada (Chatterjee et al., 2020; Malik et al., 2023; Ali et al., 2023; Rakshit & Das, 2018; Bing et al., 2024; Jia et al., 2024). Los filtros clásicos FIR, IIR y notch ofrecen una buena SNR para ruidos simples como BW o PLI aislados y presentan baja complejidad computacional, pero muestran peor PRD y pueden introducir distorsión en las ondas P y T cuando el ancho de banda no se ajusta adecuadamente (Kher, 2019; Zia-Ul-Haque et al., 2019; Ali et al., 2023). Los filtros adaptativos LMS, NLMS, RLS y sus variantes alcanzan mayor SNRimp para ruidos no estacionarios como EMG y MA, así como para PLI variable, con un coste computacional bajo a medio en el caso de LMS, NLMS y Sign-LMS, y más elevado para RLS, kernel-RLS, PNLMS e IPNLMS; la preservación morfológica es buena cuando se ajustan correctamente el orden y el paso, evaluándose mediante métricas de correlación y errores sobre el complejo QRS (Zia-Ul-Haque et al., 2019; Mohaddes et al., 2020; Faiz & Kale, 2022; Galdos et al., 2024). Los métodos wavelet DWT y SWT presentan en varios estudios el mejor compromiso entre SNR, MSE y preservación del complejo P-QRS-T frente a los filtros clásicos, aunque requieren una elección cuidadosa de la función madre wavelet, el nivel de descomposición y el umbral, y pueden verse afectados por problemas de aliasing y falta de invariancia a traslación (Chatterjee et al., 2020; Ali et al., 2023; Xie et al., 2020; Jia et al., 2024). Los métodos basados en EMD, IF y VMD ofrecen una gran capacidad de adaptación espectro-temporal y buena preservación morfológica, pero EMD sufre mezclado de modos y elevado coste computacional, mientras que IF y VMD mejoran la estabilidad a costa de mayor complejidad (Malik et al., 2023; Rakshit & Das, 2018; Mir & Singh, 2023; Jia et al., 2024). Finalmente, los híbridos optimizados como PSO-WT, EMD+ASMF, IF+LWT y VMD+EWT típicamente ofrecen los mejores SNR y PRD y la mayor preservación morfológica, pero con el mayor coste computacional y la mayor complejidad de implementación, lo que los sitúa preferentemente en entornos de procesamiento offline o en la nube (Malik et al., 2023; Azzouz et al., 2024; Rakshit & Das, 2018; Mir & Singh, 2023; Jia et al., 2024).

Detección análisis y extracción

La detección precisa de las ondas P, QRS y T y la extracción de características derivadas de ellas constituyen el núcleo del análisis automático de ECG, pues de su exactitud dependen directamente el cálculo de intervalos clínicos PR, QRS, QT y RR, la estimación de la

variabilidad de frecuencia cardíaca (HRV) y la clasificación de arritmias y patologías. Los métodos clásicos de segmentación de ondas se basan en combinaciones de filtrado diferencial, transformadas wavelet y umbrales adaptativos; el algoritmo de Pan-Tompkins sigue siendo referente para la delimitación del complejo QRS por su robustez y baja carga computacional, alcanzando sensibilidades superiores al 99% sobre MIT-BIH, mientras que extensiones basadas en DWT permiten la detección simultánea de ondas P y T con tasas de error inferiores al 1% en señales de baja relación SNR (Malik et al., 2023; Malghan & Hota, 2020). La extracción de características temporales comprende los intervalos PR, QRS y QT, las amplitudes de cada onda y la duración del ciclo RR, mientras que las características frecuenciales se obtienen mediante FFT, DWT y análisis tiempo-frecuencia como la S-transform, capturando la distribución espectral de la señal en bandas clínicamente relevantes; la combinación de ambos dominios ha demostrado mejorar consistentemente la precisión clasificatoria frente al uso exclusivo de características de un solo dominio (Chatterjee et al., 2020; Xie et al., 2020; Śmigiel et al., 2021).

El análisis de HRV a partir de la serie RR se realiza tanto en dominio temporal SDNN, RMSSD, pNN50 como frecuencial bandas LF, HF y ratio LF/HF y no lineal entropía aproximada, entropía muestral, análisis de fluctuación sin tendencia (DFA); estos indicadores constituyen biomarcadores sensibles del equilibrio autonómico y se han empleado para la detección temprana de fibrilación auricular, insuficiencia cardíaca congestiva y otras patologías (Xie et al., 2020; Jia et al., 2024). En el ámbito del aprendizaje profundo, redes CNN 1D entrenadas directamente sobre segmentos de señal centrados en el complejo QRS siguiendo la taxonomía AAMI de cinco clases logran precisiones del 98–99% eliminando la necesidad de ingeniería manual de características, mientras que arquitecturas híbridas CNN+LSTM capturan simultáneamente patrones morfológicos locales y dependencias temporales de largo alcance, superando a modelos puramente convolucionales o recurrentes en bases de datos de alta variabilidad como PTB-XL (Romdhane et al., 2020; Śmigiel et al., 2021; Jia et al., 2024). En cuanto a las comparaciones cuantitativas, los métodos clásicos basados en wavelet ofrecen tasas de detección de onda P superiores al 98% con porcentajes de error inferiores al 2% en señales con SNR mayor de 10 dB, pero su rendimiento se degrada significativamente por debajo de 5 dB de SNR; los modelos de aprendizaje profundo, en cambio, mantienen F1-scores superiores al 97% incluso a SNR de 0 dB, a costa de requerir grandes volúmenes de datos etiquetados y recursos GPU para el entrenamiento (Peng et al., 2023; Jia et al., 2024). Finalmente, la implementación en Python de este pipeline completo desde la detección de ondas hasta la clasificación se apoya en NeuroKit2 y BioSPPy para la segmentación y extracción de características clásicas, PyWavelets para el análisis wavelet, y TensorFlow o PyTorch para los modelos de aprendizaje profundo, con acceso estandarizado a las bases MIT-BIH, NSTDB y PTB-XL a través de la librería WFDB (Xie et al., 2020; Chatterjee et al., 2020).

La Figura 2 muestra una clasificación general de las principales técnicas empleadas en el procesamiento y filtrado de señales ECG, organizadas según su enfoque metodológico y complejidad computacional, abarcando desde métodos clásicos hasta enfoques híbridos y algoritmos basados en aprendizaje profundo.

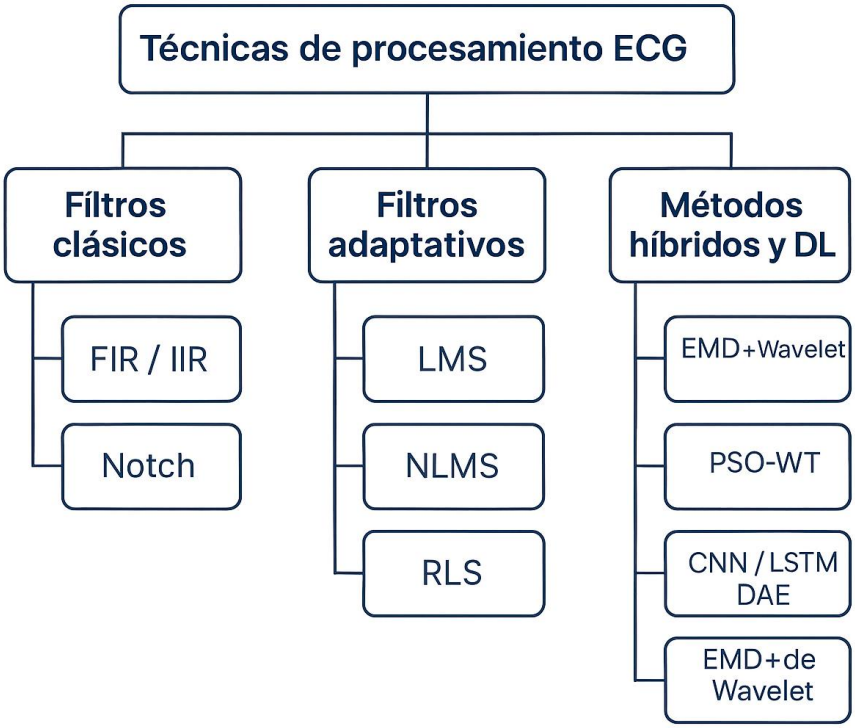

Figura 2. Clasificación de las técnicas de procesamiento y denoising de señales ECG según su enfoque: filtros clásicos, filtros adaptativos y métodos híbridos y basados en aprendizaje profundo.

Del análisis comparativo se desprende que ninguna técnica ofrece un desempeño óptimo en todos los escenarios, lo cual justifica un enfoque flexible y configurable, objetivo central de la plataforma propuesta.

Tabla Resumen de técnicas existentes

Método	Tipo de Ruido	SNR	MSE	Complejidad	Tiempo Real	Ventajas	Limitación
FIR/IRR	PLI, BW	Medio	Medio	Baja	Si	Fácil implementación	Pobre con ruido no estacionario
Filtro Notch	PLI	Alto	Bajo	Baja	Si	Muy eficaz en 50/60hz	Solo ruido especifico
LMS	MA, EMG	Alto	Bajo	Baja	Si	Adaptativo, bajo costo	Requiere ajuste de parámetros
NLMS	MA, EMG	Muy Alto	Bajo	Media	Si	Mejor convergencia	Mayor costo que LMS
RLS	PLI, MA	Muy alto	Muy Bajo	Alta	Limitado	Alta precisión	Alto costo computacional

DWT	BW, EMG, Ruido compuesto	Muy alto	Muy Bajo	Media	Parcial	Excelente preservación	Sensible a parámetros
SWT	BW, EMG	Muy alto	Muy Bajo	Alta	No	Mejor que DWT en morfología	Alto costo
EMD	Ruido no estacionario	Muy alto	Bajo	Alta	No	Adaptativo	Mezcla de modos
VMD	Ruido complejo	Muy alto	Muy Bajo	Alta	No	Mejor que EMD	Complejo
IF + WAVELET	Ruido compuesto	Muy alto	Muy Bajo	Media	Si	Balance ideal	Implementación más compleja

Relación con la plataforma propuesta

A partir del análisis comparativo de las técnicas de filtrado revisadas, se evidencia que no existe un método único que resulte óptimo para todas las condiciones de señal ECG, dado que el desempeño de cada enfoque depende del tipo de ruido presente, la calidad de la señal adquirida y los requisitos computacionales del escenario de aplicación. Esta diversidad de condiciones impide la adopción de soluciones rígidas basadas en una sola técnica de procesamiento.

En este contexto, la plataforma propuesta no se limita a la implementación de un único método de filtrado, sino que adopta un enfoque flexible y modular que permite la selección y comparación de diferentes técnicas, incluyendo filtros digitales clásicos, filtros adaptativos y métodos basados en wavelets. Esta decisión de diseño se fundamenta directamente en los resultados del estado del arte, que demuestran que cada técnica presenta ventajas y limitaciones específicas según el tipo de ruido y las condiciones de adquisición.

Dicho enfoque posibilita la adaptación del procesamiento a las características particulares de cada señal ECG, brindando al usuario la capacidad de seleccionar el método más adecuado según el escenario de análisis. Asimismo, permite realizar evaluaciones comparativas entre técnicas mediante métricas cuantitativas como SNR y MSE, así como criterios de preservación morfológica, favoreciendo un análisis más objetivo y fundamentado del desempeño de los distintos algoritmos.

Desde el punto de vista computacional, se prioriza la implementación de métodos que puedan ejecutarse de forma eficiente en entornos web, garantizando tiempos de respuesta adecuados para aplicaciones interactivas y multiusuario. No obstante, la arquitectura del sistema contempla también la integración de técnicas más avanzadas y computacionalmente exigentes, las cuales pueden emplearse en análisis offline o en sistemas con mayor capacidad de procesamiento, manteniendo así la escalabilidad del sistema.

De esta manera, la plataforma no solo se concibe como una herramienta de análisis automático de señales ECG, sino también como un entorno de experimentación y aprendizaje, que permite explorar y comparar el comportamiento de distintas técnicas de

filtrado bajo un marco unificado y accesible, reforzando su valor tanto en contextos educativos como de investigación y desarrollo.

2.2 Herramientas y tecnologías de implementación

La implementación integral del pipeline de procesamiento, filtrado y análisis de señales ECG puede realizarse completamente en un ecosistema unificado Python–Web, combinando el poder computacional de las librerías científicas de Python en el backend con tecnologías HTML, CSS y JavaScript en el frontend para la visualización interactiva y el despliegue clínico o de investigación. En el núcleo del backend, NumPy y SciPy proveen las estructuras de datos y rutinas optimizadas para el diseño y aplicación de filtros FIR e IIR, filtros notch, algoritmos adaptativos LMS y NLMS, y la transformada wavelet discreta mediante su módulo scipy.signal y scipy.fft (Xie et al., 2020); PyWavelets complementa esta base con implementaciones completas de DWT y SWT para múltiples familias de funciones madre Daubechies, Symlets, Coiflets y esquemas de umbralado suave y duro, replicando fielmente los flujos de trabajo reportados en la literatura sobre denoising wavelet (Chatterjee et al., 2020; Ali et al., 2023). Para los métodos basados en descomposición modal, PyEMD cubre EMD, EEMD y CEEMDAN, mientras que vmdpy permite implementar VMD, posibilitando la reproducción de los esquemas híbridos EMD+wavelet y VMD+EWT con métricas de evaluación SNR, MSE y PRD calculadas directamente sobre los arrays resultantes (Dai & Bai, 2021; Mir & Singh, 2023). La optimización de parámetros wavelet mediante PSO se integra a través de PySwarms, que permite definir una función objetivo basada en SNR o PRD y ajustar automáticamente el tipo de función madre, el nivel de descomposición y el umbral, reproduciendo el esquema PSO-WT reportado por Azzouz et al. (2024) con SNR de salida de aproximadamente 27.5 dB para PLI a 60 Hz.

En el ámbito del aprendizaje profundo, TensorFlow y PyTorch constituyen los frameworks principales para la implementación de DAE, redes CNN 1D, arquitecturas CNN+LSTM, U-Net y modelos GAN orientados al filtrado y clasificación de ECG; Keras integrado en TensorFlow facilita la construcción modular de estas arquitecturas con capas Conv1D, LSTM, BatchNormalization y Dropout, mientras que PyTorch ofrece mayor flexibilidad para arquitecturas personalizadas como ST-Res U-Net e IncRes-U-Net (Peng et al., 2023; Romdhane et al., 2020; Jia et al., 2024). El acceso estandarizado a las bases de datos MIT-BIH, NSTDB y PTB-XL se realiza mediante la librería WFDB, que permite la carga, segmentación y anotación de registros directamente en Python, facilitando la construcción de conjuntos de entrenamiento y prueba bajo la taxonomía AAMI de cinco clases (Romdhane et al., 2020; Śmigiel et al., 2021). Para la extracción de características clínicas intervalos PR, QRS, QT, HRV en dominios temporal, frecuencial y no lineal, NeuroKit2 y BioSPPy ofrecen pipelines completos que integran detección de ondas P, QRS y T, cálculo de SDNN, RMSSD, pNN50 y análisis espectral LF/HF, exportando los resultados en DataFrames de Pandas listos para su análisis estadístico o alimentación de modelos supervisados (Xie et al., 2020).

En el frontend, la visualización interactiva del pipeline completo se construye con HTML5, CSS3 y JavaScript, combinando librerías especializadas para lograr una interfaz clínica funcional y comparativa. Plotly.js permite renderizar las señales ECG crudas y filtradas en gráficas interactivas con zoom, pan y selección de segmentos, así como gráficas comparativas de SNR, MSE y PRD entre métodos mediante barras y líneas con tooltips detallados; Chart.js complementa esta visualización con gráficos de radar para comparaciones multimétrica entre algoritmos y gráficas de dispersión para la representación del espacio de características HRV (Xie et al., 2020; Jia et al., 2024). D3.js ofrece el mayor nivel de personalización para la construcción de visualizaciones avanzadas como espectrogramas tiempo-frecuencia, mapas de calor de coeficientes wavelet por nivel de descomposición y diagramas de flujo interactivos del pipeline de procesamiento. La comunicación entre el backend Python y el frontend web se establece mediante una API REST construida con FastAPI o Flask, que expone endpoints para la carga de señales ECG en formato WFDB o CSV, la selección interactiva del método de filtrado y sus parámetros, la ejecución del pipeline completo y la devolución de los resultados señal filtrada, métricas SNR/MSE/PRD y características extraídas en formato JSON para su renderizado inmediato en el frontend (Nawaz & Ahmed, 2022). Para el despliegue en tiempo real de modelos de aprendizaje profundo, TensorFlow.js permite exportar modelos entrenados en Python y ejecutarlos directamente en el navegador sin servidor intermedio, habilitando la inferencia en edge con latencias del orden de milisegundos sobre hardware estándar; alternativamente, ONNX Runtime Web ofrece compatibilidad multiplataforma para modelos exportados desde PyTorch (Jia et al., 2024). El diseño de la interfaz se implementa con CSS Grid y Flexbox para una disposición responsiva de paneles señal cruda, señal filtrada, espectro de frecuencias, métricas comparativas y características HRV, complementado con Tailwind CSS para la estilización rápida de componentes clínicos como selectores de método, sliders de parámetros y tablas comparativas exportables a CSV o PDF mediante la librería jsPDF.

2. PLATAFORMAS Y ARQUITECTURAS

3.1Marco normativo y estándares considerados

El desarrollo de la plataforma propuesta se enmarca en estándares y normativas reconocidas en el ámbito del procesamiento de señales biomédicas y el desarrollo de software, sin constituir un dispositivo médico certificado ni un sistema clínico de diagnóstico.

En particular, se consideran como referencia los estándares establecidos por la Association for the Advancement of Medical Instrumentation (AAMI) y la norma IEC 60601-2-25 para la evaluación de algoritmos y la preservación morfológica de señales ECG. Asimismo, se emplean bases de datos estandarizadas de uso extendido en investigación, tales como MIT-BIH y PTB-XL, que constituyen benchmarks de facto en la literatura científica.

En cuanto al manejo de datos, la plataforma adopta formatos abiertos y ampliamente utilizados como WFDB, CSV y JSON, y se diseña considerando principios generales de protección de datos y privacidad alineados conceptualmente con normativas como GDPR y HIPAA, sin almacenar información clínica sensible ni datos personales reales.

Cabe señalar que, para un eventual despliegue clínico o comercial, sería necesario cumplir con normativas adicionales de certificación de software y dispositivos médicos, tales como IEC 62304, ISO 13485 y regulaciones FDA/CE, las cuales quedan fuera del alcance del presente trabajo.

3.2 Enfoque Teórico

Plataformas Web

La tendencia reciente en plataformas web para análisis de ECG converge hacia arquitecturas cliente-servidor donde un backend de procesamiento científico se expone mediante APIs REST y un frontend web interactivo consume los resultados en tiempo casi real. ExChanGeAI representa el referente más directo para el sistema propuesto: es una plataforma web open source que integra ingestión de datos en múltiples formatos, visualización interactiva de señales y entrenamiento y fine-tuning de modelos de deep learning con cómputo local, priorizando la privacidad al evitar la subida de señales crudas a infraestructuras externas (Bickmann et al., 2026). MULTISAB y WebSA 2.0 demuestran la viabilidad de arquitecturas frontend–backend multiusuario para análisis de señales biomédicas con módulos de preprocesado, extracción de características y sistemas de reporting accesibles desde navegador (Cano-Ortiz et al., 2017; Jović et al., 2018). Un sistema wearable con microcontrolador STM32L151xD expone sus datos a través de un servidor REST que alimenta un módulo web para filtrado, segmentación PQRST y detección de anomalías, validando el patrón arquitectónico dispositivo→API REST→frontend web en un entorno real (Alimbayeva et al., 2024).

Cloud Computing y procesado intensivo

El marco AWS de Nawaz & Ahmed (2022) estructura el pipeline en preprocesado local, compresión por wavelet scattering y análisis con autoencoders LSTM y clasificadores en la nube, alcanzando 98–100% de exactitud sobre ECG 1D; este esquema es directamente replicable en el sistema propuesto separando el procesado ligero en local y delegando el entrenamiento de modelos complejos a infraestructura cloud como Google Colab o AWS. Los sistemas cloud acelerados por FPGA demuestran que la separación en capas adquisición, procesado y análisis ML mejora drásticamente el rendimiento (Wang et al., 2017), principio aplicable al diseño modular del backend FastAPI propuesto. Arquitecturas de comunicación semántica en tres niveles edge, relé y cloud logran razón de compresión de 0.019 y exactitud de clasificación de 0.988, ilustrando estrategias de partición de carga entre nodo local y cloud (Yang et al., 2024).

Edge e IoT como referente de latencia

Arquitecturas fog–cloud con CNN 1D demuestran que situar la inferencia cerca del origen de los datos reduce el tiempo de respuesta global en ~25% respecto a esquemas totalmente remotos (Cheikhrouhou et al., 2021); en el sistema propuesto, ejecutar el backend FastAPI localmente para inferencia crítica y delegar el entrenamiento a cloud replica exactamente este patrón híbrido. Implementaciones TinyML sobre Raspberry Pi con precisión ~92% y consumo de 0.024 mW confirman que modelos CNN 1D ligeros son suficientes para clasificación en tiempo real sin cloud (Hizem et al., 2025), mientras que el nodo cognitivo IoMT con CNN y adaptatividad dinámica alcanza más del 97% de exactitud en microcontrolador (Scrugli et al., 2021), validando la viabilidad del enfoque híbrido local+cloud propuesto.

3.3 Enfoque práctico

Arquitectura cliente-servidor híbrida con FastAPI y Python

La arquitectura del sistema propuesto sigue un patrón híbrido local–cloud donde FastAPI actúa como capa de exposición del backend científico Python mediante endpoints REST, ejecutándose localmente para tareas de filtrado e inferencia en tiempo real y apoyándose en cloud para entrenamiento de modelos y almacenamiento masivo. FastAPI expone rutas para la recepción de señales ECG en formato JSON o CSV, la selección del método de filtrado FIR, IIR, LMS, NLMS, DWT, VMD y la devolución de señal filtrada con métricas SNR, MSE y PRD calculadas con NumPy y SciPy, con validación automática mediante Pydantic y documentación interactiva vía Swagger UI (Alimbayeva et al., 2024; Nawaz & Ahmed, 2022). El backend integra módulos de filtrado clásico con scipy.signal, métodos wavelet con PyWavelets, algoritmos adaptativos en NumPy, descomposición modal con PyEMD y vmdpy, y modelos de deep learning DAE, CNN 1D, LSTM cargados con TensorFlow/Keras o PyTorch; para el entrenamiento de modelos complejos, el sistema se conecta a Google Colab o AWS mediante llamadas a la misma API, exportando los modelos entrenados en formato ONNX para su inferencia local eficiente (Jia et al., 2024; Cheikhrouhou et al., 2021). La librería WFDB permite cargar registros MIT-BIH y PTB-XL directamente desde el backend para validación sobre bases de datos estandarizadas sin modificar el flujo de la API (Romdhane et al., 2020).

La Figura 3 muestra la arquitectura general de la plataforma propuesta, basada en un enfoque híbrido local–cloud que integra un backend científico en Python, un frontend web interactivo y el acceso a bases de datos estandarizadas, permitiendo equilibrar capacidad de procesamiento, latencia y accesibilidad.

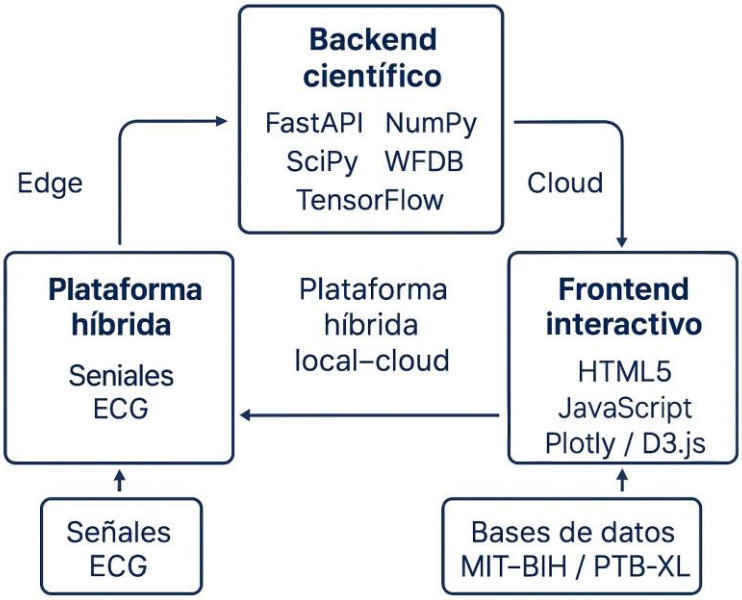

Figura 3. Arquitectura híbrida local–cloud de la plataforma web para el análisis automático de señales ECG, integrando backend científico, frontend interactivo y bases de datos estandarizadas.

Frontend web: HTML, CSS y JavaScript

El frontend se construye en HTML5, CSS3 y JavaScript, estructurado en paneles funcionales que consumen los endpoints REST del backend FastAPI mediante Axios o la Fetch API nativa. La visualización de señales ECG crudas y filtradas se implementa con Plotly.js, que renderiza gráficas interactivas con zoom, pan y selección de segmentos sobre los arrays JSON devueltos por la API, así como gráficas comparativas de SNR, MSE y PRD entre métodos mediante barras agrupadas y líneas con tooltips detallados (Xie et al., 2020; Jia et al., 2024). Chart.js complementa la visualización con gráficos de radar para comparaciones multimétrica entre algoritmos y dispersión para el espacio de características HRV. D3.js se emplea para visualizaciones avanzadas como mapas de calor de coeficientes wavelet por nivel de descomposición, espectrogramas tiempo-frecuencia y diagramas de flujo interactivos del pipeline. El diseño responsivo se implementa con CSS Grid y Flexbox complementado con Tailwind CSS para la estilización de componentes selectores de método, sliders de parámetros, tablas comparativas y botones de exportación a CSV y PDF mediante jsPDF (Seddiki et al., 2024; Bickmann et al., 2026). Para la inferencia de modelos ligeros directamente en el navegador sin llamada al backend, TensorFlow.js permite cargar modelos exportados desde Python y ejecutarlos en el cliente con latencias del orden de milisegundos, mientras que ONNX Runtime Web ofrece compatibilidad para modelos exportados desde PyTorch (Jia et al., 2024).

Dashboards y sistemas de referencia

Los dashboards de referencia más relevantes combinan visualización en tiempo real, selección interactiva de parámetros y comparación de métricas en una interfaz unificada. Sistemas IoT con Node-RED presentan frecuencia cardíaca, SpO_2 y clasificaciones de arritmia con tiempos de respuesta de 55–164 ms integrando TensorFlow.js en el flujo de visualización (Seddiki et al., 2024), validando que la integración de inferencia DL en el frontend es viable, aunque en el sistema propuesto esta inferencia se delega preferentemente al backend Python para mayor flexibilidad y control. ExChanGeAI integra visualización interactiva de señales y métricas de entrenamiento en un dashboard accesible desde navegador orientado a investigadores (Bickmann et al., 2026), y MULTISAB demuestra la viabilidad de dashboards multiusuario con módulos de extracción de características y reporting exportable (Jović et al., 2018). La literatura identifica como vacío de investigación la escasez de plataformas que integren comparaciones sistemáticas entre métodos de filtrado bajo las mismas condiciones (Demirel et al., 2021), necesidad que el sistema propuesto aborda directamente mediante su módulo de comparación interactiva de métricas SNR, MSE y PRD sobre señales reales de MIT-BIH y PTB-XL.

3. FORMATO Y ESTANDARES

Estándares Clínicos

Los estándares clínicos para el almacenamiento e intercambio de señales ECG responden a la necesidad de interoperabilidad entre sistemas hospitalarios y plataformas de investigación. DICOM Digital Imaging and Communications in Medicine constituye el estándar internacional dominante en entornos hospitalarios para el almacenamiento y transmisión de datos médicos, incluyendo ECG de reposo y de esfuerzo de 12 derivaciones; su estructura encapsula tanto la señal como los metadatos clínicos del paciente identificación, diagnóstico, parámetros de adquisición en un único objeto, facilitando la integración con sistemas HIS y PACS y garantizando la trazabilidad clínica (Jia et al., 2024; Bickmann et al., 2026). WFDB WaveForm DataBase es el estándar de facto en investigación sobre señales fisiológicas, desarrollado por PhysioNet para las bases de datos MIT-BIH, PTB-XL y NSTDB; estructura cada registro en un archivo de cabecera .hea con los metadatos de adquisición y un archivo binario .dat con las muestras, y dispone de librería Python homónima que permite la carga, anotación y exportación de registros directamente en entornos de desarrollo científico (Romdhane et al., 2020; Śmigiel et al., 2021). HL7/FHIR Fast Healthcare Interoperability Resources emerge como estándar complementario para la transmisión de datos clínicos en arquitecturas web y cloud, permitiendo exponer registros ECG como recursos REST interoperables con sistemas hospitalarios, aunque su adopción en plataformas de investigación sigue siendo limitada (Demirel et al., 2021; Nawaz & Ahmed, 2022).

Formatos En Desarrollo E Investigación

En la práctica del desarrollo de sistemas de procesado de ECG, los formatos empleados responden a criterios de accesibilidad, compatibilidad con librerías científicas y facilidad de

manipulación, priorizando la agilidad sobre la interoperabilidad clínica. El formato. mat de MATLAB es ampliamente utilizado en estudios comparativos de filtrado y clasificación por su compatibilidad directa con los toolboxes de señal y wavelet, y es accesible desde Python mediante scipy.io, loadmat, lo que lo convierte en puente natural entre el ecosistema MATLAB de la literatura y el backend Python propuesto (Chatterjee et al., 2020; Malik et al., 2023; Ali et al., 2023). El formato .csv es el más empleado en pipelines de desarrollo por su universalidad, legibilidad directa y compatibilidad inmediata con Pandas, NumPy y los endpoints REST de FastAPI, permitiendo transmitir señales ECG como arrays JSON entre el frontend y el backend sin transformación adicional (Xie et al., 2020; Alimbayeva et al., 2024). Formatos como. edf European Data Format y .xml se emplean en dispositivos Holter y sistemas de telemonitorización respectivamente, siendo accesibles desde Python mediante librerías como pyEDFlib (Sahu et al., 2021; Seddiki et al., 2024).

En conclusión, existe una brecha significativa entre los estándares clínicos complejos DICOM, HL7/FHIR orientados a la interoperabilidad hospitalaria, y los formatos accesibles empleados en investigación y desarrollo WFDB, .mat, .csv, orientados a la agilidad computacional. El sistema propuesto aborda esta brecha adoptando WFDB como formato de acceso a bases de datos estandarizadas mediante su librería Python homónima, CSV y JSON como formatos de intercambio en la API REST, y contemplando la extensión futura hacia DICOM y HL7/FHIR para la integración clínica, siguiendo la tendencia identificada en la literatura como uno de los principales vacíos de investigación (Demirel et al., 2021; Bickmann et al., 2026).

4. VISUALIZACIÓN E INTERACCIÓN

Dashboards Médicos E Interfaces Adaptativas

La visualización de señales ECG en entornos clínicos y de investigación ha evolucionado desde representaciones estáticas hacia dashboards interactivos que integran múltiples parámetros fisiológicos, métricas de calidad de señal y resultados de clasificación en una interfaz unificada accesible desde navegador. Sistemas IoT multiparámetro basados en Node-RED presentan en tiempo real frecuencia cardíaca, SpO_2, temperatura y clasificaciones de arritmia con tiempos de respuesta de 55–164 ms, demostrando la viabilidad de dashboards clínicos web con integración de modelos DL en el flujo de visualización (Seddiki et al., 2024). ExChanGeAI integra visualización interactiva de señales ECG, curvas de entrenamiento de modelos y métricas de evaluación en un dashboard unificado orientado a investigadores, con capacidad de fine-tuning interactivo (Bickmann et al., 2026). MULTISAB y WebSA 2.0 demuestran la viabilidad de interfaces multiusuario con módulos de carga, preprocesado, visualización de características y reporting exportable, empleadas en entornos de investigación clínica colaborativa (Cano-Ortiz et al., 2017; Jović et al., 2018). La tendencia en interfaces adaptativas apunta hacia sistemas que ajustan el nivel de detalle y las opciones disponibles según el perfil del usuario clínico, investigador o técnico,

identificándose la falta de adaptación al tipo de usuario como uno de los vacíos más relevantes en las plataformas actuales (Jia et al., 2024; Demirel et al., 2021).

librerías web y tipos de usuario

En el plano de la implementación, las librerías JavaScript de visualización científica constituyen el componente central del frontend para sistemas de análisis ECG. Plotly.js es la librería más empleada para la representación interactiva de señales biomédicas por su soporte nativo de zoom, pan, selección de segmentos y exportación de figuras, permitiendo renderizar directamente los arrays JSON devueltos por la API REST sin transformación adicional; su integración con FastAPI y Axios permite actualizar las gráficas en tiempo casi real tras cada llamada al backend (Xie et al., 2020; Jia et al., 2024). D3.js ofrece el mayor nivel de personalización para visualizaciones avanzadas como mapas de calor de coeficientes wavelet, espectrogramas tiempo-frecuencia, diagramas de flujo del pipeline de procesado y representaciones de HRV en dominios temporal y frecuencial; su curva de aprendizaje más elevada la hace preferible para componentes fijos de alta complejidad visual (Bing et al., 2024). Chart.js complementa ambas con gráficos de radar para comparaciones multimétrica entre algoritmos de filtrado y gráficas de barras agrupadas para SNR, MSE y PRD. En cuanto a los tipos de usuario, la literatura distingue dos perfiles principales: el usuario experto investigador o ingeniero biomédico que requiere acceso a parámetros detallados de cada método, visualización de coeficientes intermedios y exportación de resultados en formatos científicos; y el usuario no experto clínico o paciente que necesita una interfaz simplificada con indicadores visuales claros, alertas automáticas y resultados interpretables sin conocimiento técnico del pipeline subyacente (Bickmann et al., 2026; Alimbayeva et al., 2024; Jović et al., 2018).

5. ANALISIS COMPARATIVO

Autor	Método/Sistema	Plataforma	Ventajas	Limitaciones
Nawaz & Ahmed (2022)	Pipeline ECG 1D: wavelet scattering + LSTM-AE + clasificador	AWS cloud (Python)	98–100% exactitud; detección anomalías + clasificación multiclase en un marco unificado	Dependencia total de cloud; latencia elevada; sin interfaz web interactiva
Cheikhrouhou et al. (2021)	CNN 1D en arquitectura fog–cloud	Python + Google Colab	F1 ≈ 1; 25% menos latencia que cloud puro; equilibra precisión y tiempo de respuesta	Complejidad de orquestación fog–cloud; sin frontend de visualización integrado
Bickmann et al. (2026)	ExChanGeAI: plataforma DL end-to-end para-ECG	Web + Python + HPC/local	Pipeline completo ingestión–visualización–entrenamiento; preserva privacidad; open source	No centrada en streaming; requiere recursos locales significativos para modelos grandes

Ali et al. (2023)	DWT con umbralado único para BW, PLI, ruido blanco y EMG	MATLAB	SNR BW ≈ 25 dB, PLI ≈ 26 dB; MSE 0.003–0.13; supera filtros clásicos	Solo MATLAB; sin interfaz web ni comparación interactiva de métodos
Azzouz et al. (2024)	PSO-WT: optimización automática de parámetros wavelet	MATLAB + PSO toolbox	SNR ≈ 27.5 dB para PLI; supera >10 métodos de referencia	Elevada complejidad computacional; no apto para tiempo real sin optimización
Malik et al. (2023)	IF + LWT para BW y PLI	MATLAB	Mejor SNR, correlación y PRD que EMD+wavelet y RLS+Hilbert; base matemática sólida	Implementación compleja; sin despliegue web ni comparación con deep learning
Dai & Bai (2021)	EMD + filtro adaptativo paralelo para ruido compuesto	MATLAB	Mejor SNRimp sobre MIT-BIH con BW+PLI+EMG+MA simultáneos	Mezclado de modos; alto coste computacional; sin frontend
Scrugli et al. (2021)	CNN cognitiva en nodo IoMT con adaptatividad dinámica	Microcontrolador + Python	>97% exactitud; ahorro 50% energía; operación sin cloud	Limitado en complejidad de modelos; sin visualización ni comparación de filtros
Seddiki et al. (2024)	Sistema IoT multiparámetro con DL y dashboard Node-RED	ESP32 + Raspberry Pi + cloud	Dashboard en tiempo real; 55–164 ms latencia; integra ECG, SpO_2, temperatura	Dependencia de hardware IoT específico; sin módulo de comparación de métodos de filtrado
Alimbayeva et al. (2024)	Wearable ECG + servidor REST + módulo web ML	STM32 + Python + web	Patrón REST validado en entorno real; filtrado + segmentación + anomalías en web	Sin comparación interactiva de métodos ni métricas SNR/MSE/PRD exportables
Jović et al. (2018)	MULTISAB: plataforma web multiusuario para señales biomédicas	Web + backend centralizado	Multiusuario; extracción de características; reporting exportable	Sin deep learning integrado; sin comparación de métodos de filtrado

6. LIMITACIONES ACTUALES

La revisión de la literatura permite identificar un conjunto de limitaciones transversales que persisten en los sistemas actuales de procesado y análisis de señales ECG, independientemente del enfoque metodológico o arquitectónico adoptado.

La falta de accesibilidad constituye la limitación más extendida: la mayoría de los métodos de filtrado avanzados PSO-WT, EMD+ASMF, IF+LWT, VMD+EWT están implementados exclusivamente en MATLAB y requieren conocimientos especializados para su uso, sin interfaces web que permitan su aplicación a usuarios no expertos o en entornos clínicos sin software propietario (Chatterjee et al., 2020; Ali et al., 2023; Azzouz et al., 2024; Malik et al., 2023).

Las interfaces complejas o inexistentes representan otro vacío crítico: la mayoría de los trabajos revisados se limitan a scripts de procesado sin frontend asociado, y las pocas plataformas con interfaz web MULTISAB, WebSA 2.0 no integran métodos de filtrado avanzados ni comparación interactiva de métricas, mientras que las plataformas con deep learning ExChanGeAI no están orientadas a la comparación sistemática de métodos de filtrado (Cano-Ortiz et al., 2017; Jović et al., 2018; Bickmann et al., 2026).

La poca integración completa del pipeline es otra limitación recurrente: los trabajos que destacan en filtrado carecen de módulos de clasificación, y viceversa; raramente un único sistema integra filtrado clásico, filtrado adaptativo, métodos modales, deep learning, extracción de características HRV y clasificación de arritmias en un pipeline unificado con comparación cuantitativa entre etapas (Jia et al., 2024; Chatterjee et al., 2020).

La dependencia de infraestructura limita la reproducibilidad y el despliegue clínico: sistemas con alto rendimiento como PSO-WT o las arquitecturas cloud AWS requieren infraestructuras costosas o conexión permanente a internet, mientras que las soluciones edge de alta precisión dependen de hardware IoT específico que no siempre está disponible en entornos de investigación o atención primaria (Nawaz & Ahmed, 2022; Wang et al., 2017; Scrugli et al., 2021; Hizem et al., 2025).

La baja interoperabilidad entre estándares clínicos y formatos de desarrollo constituye una barrera para la traslación clínica: la brecha entre DICOM y HL7/FHIR por un lado, y WFDB, .mat y .csv por otro, dificulta la integración de los sistemas desarrollados en investigación con los flujos de trabajo hospitalarios reales, siendo identificada por la literatura como uno de los principales vacíos pendientes de resolución (Demirel et al., 2021; Nawaz & Ahmed, 2022; Bickmann et al., 2026).

7. CONCLUCIONES

Tendencias actuales

La literatura reciente converge hacia tres tendencias dominantes en el procesado y análisis de señales ECG. En el plano metodológico, los métodos híbridos que combinan transformadas clásicas DWT, VMD con optimización metaheurística PSO o aprendizaje profundo DAE, CNN 1D, LSTM representan el estado del arte en filtrado y clasificación, superando consistentemente a los métodos aislados en SNR, PRD y preservación morfológica (Chatterjee et al., 2020; Azzouz et al., 2024; Jia et al., 2024). En el plano arquitectónico, la integración edge–fog–cloud con partición inteligente de funciones inferencia en el borde, entrenamiento en la nube se consolida como el paradigma dominante para sistemas de monitorización en tiempo real (Cheikhrouhou et al., 2021; Demirel et al., 2021; Kumar & Rajaram, 2024). En el plano de las plataformas, el ecosistema Python NumPy, SciPy, PyWavelets, TensorFlow, FastAPI junto con frontends web basados en JavaScript Plotly.js, D3.js emerge como la combinación más versátil para el desarrollo de sistemas de análisis ECG reproducibles, accesibles y desplegables en entornos híbridos local–cloud (Xie et al., 2020; Bickmann et al., 2026).

Tecnologías dominantes

En el backend, Python con FastAPI, TensorFlow/Keras, PyWavelets y WFDB constituye el stack tecnológico de referencia para sistemas de procesado de ECG que combinen filtrado clásico, métodos modales y deep learning con exposición mediante API REST. En el frontend, Plotly.js y D3.js lideran la visualización interactiva de señales biomédicas, mientras que Tailwind CSS y la Fetch API/Axios cubren la capa de diseño responsivo y comunicación asíncrona con el backend. En cuanto a bases de datos, MIT-BIH y PTB-XL sobre PhysioNet/WFDB son los benchmarks estandarizados de referencia para la validación de métodos de filtrado y clasificación (Romdhane et al., 2020; Śmigiel et al., 2021; Ali et al., 2023).

Vacíos existentes

La literatura identifica cuatro vacíos principales: la ausencia de plataformas web que integren de forma unificada filtrado avanzado, clasificación con deep learning y comparación interactiva de métricas; la escasez de evaluaciones comparativas sistemáticas entre métodos bajo las mismas condiciones experimentales; la falta de adopción de estándares clínicos DICOM, HL7/FHIR en plataformas de investigación; y la carencia de interfaces adaptativas que sirvan simultáneamente a usuarios expertos e inexpertos (Demirel et al., 2021; Jia et al., 2024; Bickmann et al., 2026; Chatterjee et al., 2020).

Aportación del proyecto

El sistema propuesto aborda directamente estos vacíos mediante una plataforma web de arquitectura híbrida local–cloud que integra en un único entorno: un backend Python con FastAPI que implementa el pipeline completo de filtrado FIR, IIR, LMS, NLMS, DWT,

VMD, DAE, CNN 1D, LSTM, extracción de características HRV y comparación cuantitativa de métricas SNR, MSE y PRD; y un frontend HTML5/CSS3/JavaScript con Plotly.js y D3.js que ofrece visualización interactiva y accesibilidad para usuarios expertos y no expertos. Al adoptar WFDB, CSV y JSON como formatos de acceso y contemplar la extensión hacia DICOM y HL7/FHIR, el sistema tiende un puente entre la investigación y la práctica clínica, contribuyendo a cerrar la brecha de accesibilidad, integración e interoperabilidad identificada en la literatura.

8. BIBLIOGRAFIA

- Al-Safi, A. (2021). ECG signal denoising using a novel approach of adaptive filters for real-time processing. International Journal of Electrical and Computer Engineering, 11, 1243–1249. https://doi.org/10.11591/ijece.v11i2.pp1243-1249
- Ali, M., Ali, S., & Khorsheed, A. (2023). ECG signal denoising using discrete wavelet transform. The Journal of Duhok University. https://doi.org/10.26682/csjuod.2023.26.2.42
- Alimbayeva, Z., Alimbayev, C., Kassymbek, O., Bayanbay, N., & Ozhikenova, A. (2024). Wearable ECG device and machine learning for heart monitoring. Sensors (Basel, Switzerland), 24. https://doi.org/10.3390/s24134201
- Azzouz, A., Bengherbia, B., Wira, P., Alaoui, N., Souahlia, A., Maazouz, M., & Hentabeli, H. (2024). An efficient ECG signals denoising technique based on the combination of particle swarm optimisation and wavelet transform. Heliyon, 10. https://doi.org/10.1016/j.heliyon.2024.e26171
- Bickmann, L., Plagwitz, L., Büscher, A., Eckardt, L., & Varghese, J. (2026). End-to-end platform for electrocardiogram analysis and model fine-tuning: Development and validation study. Journal of Medical Internet Research, 28. https://doi.org/10.2196/81116
- Bing, P., Liu, W., Zhai, Z., Li, J., Guo, Z., Xiang, Y., He, B., & Zhu, L. (2024). A novel approach for denoising electrocardiogram signals to detect cardiovascular diseases using an efficient hybrid scheme. Frontiers in Cardiovascular Medicine, 11. https://doi.org/10.3389/fcvm.2024.1277123
- Cano-Ortiz, S., Langmann, R., Martinez-Cañete, Y., Lombardía-Legrá, L., Herrero-Betancourt, F., & Jacques, H. (2017). A web-based tool for biomedical signal management. 758–763. https://doi.org/10.1007/978-3-319-64352-6_71
- Chatterjee, S., Thakur, R., Yadav, R., Gupta, L., & Raghuvanshi, D. (2020). Review of noise removal techniques in ECG signals. IET Signal Processing, 14, 569–590. https://doi.org/10.1049/iet-spr.2020.0104
- Cheikhrouhou, O., Mahmud, R., Zouari, R., Ibrahim, M., Zaguia, A., & Gia, T. (2021). One-dimensional CNN approach for ECG arrhythmia analysis in fog-cloud environments. IEEE Access, 9, 103513–103523. https://doi.org/10.1109/access.2021.3097751

- Dai, B., & Bai, W. (2021). Denoising ECG by adaptive filter with empirical mode decomposition.
- Demirel, B., Bayoumy, I., & Faruque, M. (2021). Energy-efficient real-time heart monitoring on edge–fog–cloud internet of medical things. IEEE Internet of Things Journal, 9, 12472–12481. https://doi.org/10.1109/jiot.2021.3138516
- Faiz, M., & Kale, I. (2022). Removal of multiple artifacts from ECG signal using cascaded multistage adaptive noise cancellers. Array, 14, 100133. https://doi.org/10.1016/j.array.2022.100133
- Galdos, J., Colque, N., Rodriguez, A., Quispe, J., Rendulich, J., & Espinoza, E. (2024). Comparison and evaluation of LMS-derived algorithms applied on ECG signals contaminated with motion artifact during physical activities. Applied Computer Science. https://doi.org/10.35784/acs-2024-10
- Gia, T., Jiang, M., Rahmani, A., Westerlund, T., Liljeberg, P., & Tenhunen, H. (2015). Fog computing in healthcare internet of things: A case study on ECG feature extraction. 2015 IEEE International Conference on Computer and Information Technology, 356–363. https://doi.org/10.1109/cit/iucc/dasc/picom.2015.51
- Hizem, M., Bousbia, L., Dhiab, Y., Aoueileyine, M., & Bouallègue, R. (2025). Reliable ECG anomaly detection on edge devices for internet of medical things applications. Sensors (Basel, Switzerland), 25. https://doi.org/10.3390/s25082496
- Jaber, H., Aljobouri, H., & Çankaya, I. (2022). Design of a web laboratory interface for ECG signal analysis using MATLAB builder NE. Open Computer Science, 12, 227–237. https://doi.org/10.1515/comp-2022-0244
- Jia, Y., Pei, H., Liang, J., Zhou, Y., Yang, Y., Cui, Y., & Xiang, M. (2024). Preprocessing and denoising techniques for electrocardiography and magnetocardiography: A review. Bioengineering, 11. https://doi.org/10.3390/bioengineering11111109
- Jović, A., Kukolja, D., Friganović, K., Jozic, K., & Cifrek, M. (2018). MULTISAB: A web platform for analysis of multivariate heterogeneous biomedical time-series. IFMBE Proceedings. https://doi.org/10.1007/978-981-10-9035-6_76
- Kher, R. (2019). Signal processing techniques for removing noise from ECG signals. https://doi.org/10.17303/jber.2019.3.101
- Kumar, R., & Rajaram, B. (2024). Design and simulation of an edge compute architecture for IoT-based clinical decision support system. IEEE Access, 12, 45456–45474. https://doi.org/10.1109/access.2024.3380906
- Kumar, S., & Ramachandran, P. (2022). Review on compressive sensing algorithms for ECG signal for IoT based deep learning framework. Applied Sciences. https://doi.org/10.3390/app12168368
- Malik, S., Parah, S., Aljuaid, H., & Malik, B. (2023). An iterative filtering based ECG denoising using lifting wavelet transform technique. Electronics. https://doi.org/10.3390/electronics12020387

- Malghan, P., & Hota, M. (2020). A review on ECG filtering techniques for rhythm analysis. Research on Biomedical Engineering, 36, 171–186. https://doi.org/10.1007/s42600-020-00057-9
- Mir, H., & Singh, O. (2023). Power-line interference and baseline wander elimination in ECG using VMD and EWT. Computer Methods in Biomechanics and Biomedical Engineering, 27, 2111–2130. https://doi.org/10.1080/10255842.2023.2271608
- Mohaddes, F., Da Silva, R., Akbulut, F., Zhou, Y., Tanneeru, A., Lobaton, E., Lee, B., & Misra, V. (2020). A pipeline for adaptive filtering and transformation of noisy left-arm ECG to its surrogate chest signal. Electronics. https://doi.org/10.3390/electronics9050866
- Nawaz, M., & Ahmed, J. (2022). Cloud-based healthcare framework for real-time anomaly detection and classification of 1-D ECG signals. PLOS ONE, 17. https://doi.org/10.1371/journal.pone.0279305
- Rakshit, M., & Das, S. (2018). An efficient ECG denoising methodology using empirical mode decomposition and adaptive switching mean filter. Biomedical Signal Processing and Control, 40, 140–148. https://doi.org/10.1016/j.bspc.2017.09.020
- Romdhane, T., Affes, H., & Kachouri, A. (2020). An improved classification approach for ECG signals based on feature extraction. 2020 IEEE International Conference on Design & Test of Integrated Micro & Nano-Systems.
- Rozi, N., Shaharuddin, S., Miskan, M., Ahmad, K., Salleh, M., & Hashim, F. (2024). Comparison on wavelet adaptive filter performance in denoising ECG signal. Journal of Advanced Research Design. https://doi.org/10.37934/ard.122.1.100112
- Sahu, M., Atulkar, M., Ahirwal, M., & Ahamad, A. (2021). IoT-enabled cloud-based real-time remote ECG monitoring system. Journal of Medical Engineering & Technology, 45, 473–485. https://doi.org/10.1080/03091902.2021.1921870
- Satheeskumaran, S., Sasikala, K., Neeraj, K., Senthilkumar, A., & Babu, N. (2023). IoT based ECG signal feature extraction and analysis for heart disease risk assessment. 2023 International Conference on Sustainable Computing and Smart Systems (ICSCSS), 1060–1066. https://doi.org/10.1109/icscss57650.2023.10169414
- Scrugli, M., Loi, D., Rao, L., & Meloni, P. (2021). An adaptive cognitive sensor node for ECG monitoring in the internet of medical things. IEEE Access, 10, 1688–1705. https://doi.org/10.1109/access.2021.3136793
- Seddiki, M., Bouhedda, M., Tobbal, A., Rebouh, S., & Aniba, Y. (2024). AI-driven IoT healthcare system for real-time ECG analysis and comprehensive patient monitoring. Science, Engineering and Technology. https://doi.org/10.54327/set2024/v4.i2.149
- Śmigiel, S., Pałczyński, K., & Ledziński, D. (2021). Deep learning techniques in the classification of ECG signals using R-peak detection and the QRS complex. Sensors, 21. https://doi.org/10.3390/s21238346

- Wang, X., Zhu, Y., Ha, Y., Qiu, M., & Huang, T. (2017). An FPGA-based cloud system for massive ECG data analysis. IEEE Transactions on Circuits and Systems II: Express Briefs, 64, 309–313. https://doi.org/10.1109/tcsii.2016.2556861
- Xie, L., Li, Z., Zhou, Y., He, Y., & Zhu, J. (2020). Computational diagnostic techniques for electrocardiogram signal analysis. Sensors (Basel, Switzerland), 20. https://doi.org/10.3390/s20216318
- Xu, G. (2020). IoT-assisted ECG monitoring framework with secure data transmission for health care applications. IEEE Access, 8, 74586–74594. https://doi.org/10.1109/access.2020.2988059
- Yang, M., Gao, D., Li, J., Xu, W., & Shi, G. (2024). Superimposed semantic communication for IoT-based real-time ECG monitoring. IEEE Journal of Biomedical and Health Informatics, 28, 3819–3830. https://doi.org/10.1109/jbhi.2024.3352927
- Zia-Ul-Haque, Z., Qureshi, R., Nawaz, M., Yar, F., Tunio, N., & Uzair, M. (2019). Analysis of ECG signal processing and filtering algorithms. International Journal of Advanced Computer Science and Applications. https://doi.org/10.14569/ijacsa.2019.0100370